

XimTier Inc.

Decision Intelligence Layer

HW 스펙 & MCP

기술 검토 보고서

Mac Studio M5 × Open LLM × XimTier MCP 아키텍처

작성: 2026년 5월

CONFIDENTIAL

CEO 한일 · CTO 강승식 · www.ximtier.com

본 보고서는 XimTier의 온프레미스 AI 의사결정 플랫폼 구축을 위한 하드웨어 선정 및 MCP(Model Context Protocol) 서버 개발 전략을 기술적으로 검토한 결과를 담고 있다. 주요 대상 하드웨어는 Apple Mac Studio M5급이며, LLM으로는 Qwen 3.5, Gemma 4 등 오픈소스 모델을 고려하였다.

HW 스펙	M5 Max 128GB: 충분 · M5 Ultra 256GB: 이상적 · M5 출시 2026년 6월~10월 예정
LLM 성능	Qwen 3.5 35B-A3B: ~55 tok/s · Gemma 4 26B MoE: ~50 tok/s (M5 Max 기준)
MCP 개발	4단계 · Phase1 기본(3/5) → Phase4 엔터프라이즈(5/5) · 비동기 처리 설계가 핵심
병원 도입	중소 병원: 즉시 가능 · 대학병원: 3~6개월 · 기술 장벽 아닌 조달·인증 장벽
공공기관	소규모: 6~12개월 · 중앙부처: GS인증 필수(12~18개월) · 나라장터 등록 필요
배포 전략	Cloud SaaS + On-Premise + Air-Gap 3단계 분리 운영으로 데이터 주권 확보

1.1 Mac Studio M5 현황 및 출시 일정

Apple Mac Studio M5는 2026년 5월 현재 아직 미출시 상태이며, WWDC 2026(6월 8~12일) 발표 후 2026년 여름 출시가 예상된다. 단, 글로벌 DRAM 부족으로 인해 2026년 10월로 지연될 가능성도 있다. 현재 MacBook Pro M5 Max(2026년 3월 출시)를 통해 성능을 사전 검증할 수 있다.

1.2 M5 Max vs M5 Ultra 사양 비교

CPU	18코어	36코어	분석 워커 수에 영향
GPU	40코어 (Neural Acc.)	80코어	LLM 추론 속도 직결
통합 메모리	최대 128GB	최대 256GB	LLM 크기 결정 요인
메모리 대역폭	~600 GB/s	~819 GB/s	토큰 생성 속도 직결
M4 Max 대비	+28% tok/s	+28% tok/s	Neural Acc. 효과
추정 가격	\$3,999~\$5,999	\$7,999~\$11,999	
권장 대상	중소 병원·일반 기업	대학병원·공공기관·듀얼 LLM	

1.3 메모리 배분 분석 (128GB / 256GB)

OS + 시스템	~12 GB		
XimTier 풀스택 (Rails + Redis + PostgreSQL + WhatDataAI)	~18 GB		
Qwen 3.5 35B-A3B (4-bit quantized)	~20 GB	78 GB	206 GB
Gemma 4 26B MoE 추가 (동시 운영)	~14 GB	64 GB	192 GB
Qwen 3.5 122B-A10B (MoE) 추가	~50 GB	14 GB	142 GB

* XimTier 풀스택: Rails 서버(~1GB) + Redis(~0.5GB) + PostgreSQL(~2GB) + WhatDataAI 엔진(~4GB) + OS 오버헤드

1.4 LLM 추론 성능 벤치마크 (M5 Max 실측)

Qwen 3.5 35B-A3B	35B total / 3B active	MoE	~55	AI Q&A 메인 엔진	★★★★★
Gemma 4 26B MoE	26B total / 4B active	MoE	~50	공공·의료 규제 전용	★★★★★
Llama 4 Scout	109B total / 17B active	MoE	~32	10M 컨텍스트 장문	★★★★☆
Qwen 3.5 27B	27B dense	Dense	~58	고품질 보고서	★★★★☆
Llama 3 70B	70B dense	Dense	18~28	고품질 추론	★★★☆☆
Qwen 3.5 122B-A10B	122B total / 10B active	MoE	65~88	대용량 데이터 분석	★★★★☆
Gemma 4 E4B	4B dense	Dense	~158	옛지·경량 배포	★★★★☆

* 출처: LLMCheck.net (2026.04), hardware-corner.net (2026.04), llmcheck.net blog (2026.03). MLX 프레임워크 기준.

1.5 동시 사용자 처리 능력

Pre-Seed · 파일럿 20개사	3~10명	충분	여유	큐잉으로 처리 가능
Seed · 유료 50개사	10~30명	△ 피크 시 지연	충분	M5 Ultra 전환 권장 시점
Series A · 200개사+	50~150명	부족	△ 복수 대 필요	클라우드 병행 검토
Enterprise 온프레미스	1~20명 (사내)	최적	최적	데이터 주권 완벽 충족

2.1 Gemma 4 vs Qwen 3.5 비교 분석

출시일	2026.04.02	2026.02.16	-
라이선스	Apache 2.0	Apache 2.0	동일
최대 사이즈	31B Dense / 26B MoE	397B-A17B MoE	Qwen 3.5
컨텍스트 윈도우	최대 256K	262K → 1M 확장	Qwen 3.5
지원 언어	140개+	201개 언어·방언	Qwen 3.5
지시 이해 (IFBench)	준수한 수준	76.5 (GPT-5.2 능가)	Qwen 3.5
Function Calling	BFCL 네이티브 지원	BFCL-V4 72.2 (오픈소스 1위)	Qwen 3.5
공공·규제 신뢰도	구글(미국) — 높음	Alibaba(중국) — 우려 가능	Gemma 4
M5 Max tok/s	~50 (26B MoE)	~55 (35B-A3B)	Qwen 3.5

2.2 추가 검토 모델

Llama 4 Scout	Meta (미국)	커스텀	10M 컨텍스트	대용량 데이터 탐색
Mistral Medium 3.5	Mistral (EU)	Apache 2.0	EU 출처·코딩	유럽·규제 시장
DeepSeek V4 Flash	DeepSeek (중국)	MIT	원가 효율 최강	비용 최적화 고객
Qwen 3.5 4B~9B	Alibaba	Apache 2.0	RPi5 실행 가능	엣지·경량 배포

2.3 멀티 LLM 배포 전략 (권장 구성)

메인 AI Q&A 엔진	Qwen 3.5 27B / 35B-A3B	M5 Max 128GB	일반 기업·제조·소상공인
규제 산업 전용	Gemma 4 26B MoE	M5 Ultra 256GB	공공기관·병원·금융
장문 데이터 분석	Llama 4 Scout	M5 Ultra (10M ctx)	대용량 데이터셋
비용 최적화	DeepSeek V4 Flash	M5 Max	비용 민감 고객
경량 엣지	Qwen 3.5 4B~9B	RPi5 / 모바일	오프라인·엣지 배포

핵심 원칙: 어떤 LLM을 사용하더라도 Reverse What-If 계산은 WhatDataAI 엔진이, 자연어 설명은 LLM이 담당한다. "LLM이 설명하고, XimTier가 증명한다"는 아키텍처 원칙은 불변이다.

3.1 MCP란 무엇인가

MCP(Model Context Protocol)는 Anthropic이 설계한 오픈 표준으로, LLM이 외부 도구·데이터와 표준 방식으로 연결되는 프로토콜이다. XimTier가 MCP 서버를 제공하면 Claude, ChatGPT 등 어떤 LLM이든 XimTier의 Reverse What-If 계산 엔진을 호출할 수 있다. Wolfram Alpha가 LLM의 수학 계산 엔진이 된 것처럼, XimTier는 비즈니스 의사결정 최적화의 표준 계산 엔진이 되는 것이 목표다.

3.2 전체 아키텍처 흐름

LLM / AI Agent (Claude · ChatGPT · Gemini · AI Agent)

| JSON-RPC 2.0 · MCP Protocol



| 동기(빠름) | 비동기(10~60초)



WhatDataAI 엔진 Job Queue (Sidekiq/Bull)

Reverse What-If 계산 ← 티어별 우선순위 큐



PostgreSQL (RLS) Redis Cluster S3/MinIO (org_id prefix)

테넌트 격리 Rate Limit 데이터 주권

3.3 MCP Tool 설계 — 4개 핵심 Tool

Tool Name	Description	Parameters	Execution Type	Priority
analyze_data	통계 분석 실행	dataset_id, target_column, analysis_type	동기 (즉시)	기본
reverse_whatif	Reverse What-If 계산	dataset_id, target_column, target_value, fixed_value	비동기 (job_id 즉시 반환)	★ 핵심
generate_report	AI 자동 보고서 생성	analysis_id, report_type, language	스트리밍	중요
ai_qa	AI Q&A 자유 질의	analysis_id, question	동기/스트리밍	기본

* reverse_whatif은 10~60초 소요로 비동기 처리 필수. MCP 호출 즉시 job_id를 반환하고 백그라운드에서 WhatDataAI 엔진이 처리 후 결과를 저장한다.

3.4 비동기 처리 패턴 — 가장 중요한 설계 결정

Reverse What-If 계산이 10~60초 소요되는 문제를 해결하기 위한 비동기 아키텍처:

LLM이 reverse_whatif 호출 → MCP 서버가 즉시 job_id 반환 (< 1초)

백그라운드 Job Queue에서 WhatDataAI 엔진 실행 (10~60초)

완료 후 결과를 Redis에 저장 → LLM이 polling 또는 webhook으로 수신

티어별 우선순위 큐: Enterprise → Professional → Growth → Starter

이 패턴을 Phase 1부터 잘못 설계하면 Phase 3에서 전체 재개발 필요

Phase 1 기본 MCP 서버	1~2개월	★★★★☆☆	MCP SDK 설치 Tool 스키마 4개 정의 stdio transport Claude Desktop 연동 API Key 기초 인증	@modelcontextprotocol/sdk TypeScript / Python JSON-RPC 2.0
Phase 2 프로덕션 MCP	2~3개월	★★★★☆	SSE / HTTP Streamable 스트리밍 응답 구현 Redis Rate Limiting 에러 핸들링·재시도 MCP Marketplace 등록	SSE / HTTP Streams Redis JWT Docker
Phase 3 멀티테넌트 격리	3~6개월	★★★★★	비동기 Job Queue ★ 테넌트 데이터 완전 격리 Job 상태 콜백 구현 워커 풀 티어 분리 프롬프트 인젝션 방어	Sidekiq / Bull PostgreSQL RLS S3 prefix 격리 PgBouncer
Phase 4 엔터프라이즈	지속	EXPERT	수평 확장 (Load Balancer) Redis Cluster 전환 Circuit Breaker 패턴 SLA 99.9% 달성 K8s / ECS 오케스트레이션	AWS ALB / K8s Redis Cluster Circuit Breaker Terraform

4.1 대규모 사용자 대응 — 6대 준비 항목

비동기 처리	★★★★★	회선 What-If 10~60초 → Job Queue 필수. MCP 호출 즉시 job_id 반환. 티어별 우선순위 큐.
테넌트 데이터 격리	★★★★★	PostgreSQL RLS (org_id 기반). S3/MinIO org_id prefix. Redis namespace 분리.
수평 확장	★★★★☆	MCP 서버 완전 무상태 설계. 모든 상태는 Redis/DB. 워커 풀 독립 확장.
레이트 리밋	★★★★☆	API Key별 월 행수/RWIF 횟수 카운팅. 80% 도달 시 경고 알림. Sliding Window.
모니터링	★★★★☆☆	Prometheus + Grafana + Sentry. Queue 깊이 임계값 알람. API 응답시간 P95 추적.
보안	★★★★★	프롬프트 인젝션 방어 필수. 파라미터 화이트리스트. API Key 즉시 revoke 기능.

XimTier의 핵심 가치인 "데이터 주권"은 배포 모델에 따라 충족 여부가 달라진다. Cloud SaaS MCP는 데이터가 XimTier 서버로 전송되므로 온프레미스라고 할 수 없다. 진정한 데이터 주권은 On-Premise 또는 Air-Gap 배포에서만 달성된다.

Cloud SaaS MCP	XimTier 클라우드	Claude/GPT (클라우드)	미충족	일반 기업·소상공인	현행 SaaS 과금
On-Premise MCP	기업 서버 내	Claude/GPT (결과만 전달)	△ 부분 충족	중견기업·일반 병원	+50~100% 프리미엄
Full Air-Gap	기업 서버 완전 격리	Qwen 3.5 / Gemma 4 (로컬)	완전 충족	공공기관·금융·국방	Enterprise 협의

* On-Premise MCP의 MCP 아키텍처 특성: LLM은 파라미터(dataset_id, target_value)만 전달하고, 실제 데이터는 기업 서버의 MCP 서버가 로컬에서 처리한다. Claude가 받는 것은 "온도를 2.3도 낮추세요"라는 결과값이지, 원시 데이터가 아니다.

5.1 API Key 시스템 설계

Key 포맷 (JWT 기반): ximtier_{org_id}_{tier}_{yyyymm}_{signature}

예시: ximtier_org7f3a_pro_202607_eyJhbGciOiJIUzI1NiJ9...

갱신 주기	매월 1일 자동 갱신 (결제 성공 시)
만료 알림	만료 7일 전 이메일 + 앱 알림 자동 발송
결제 실패	7일 유예기간 후 자동 만료
즉시 revoke	보안 사고 시 → Slack webhook 알림 + 신규 발급
Tier 업그레이드	당월 즉시 적용
Tier 다운그레이드	다음 달 적용
Enterprise	Key + IP Whitelist 이중 검증

6.1 기술 스펙 관점 — 충분합니다

병원과 공공기관이 실제로 다루는 데이터(10만~500만 행)와 동시 접속자(5~30명) 기준으로 M5 Max 128GB는 충분하다. 망분리 환경도 로컬 LLM 구성으로 완벽히 지원된다. 진짜 장벽은 기술이 아닌 인증·조달·절차다.

6.2 기관 유형별 도입 가능성

중소 병의원 (100~500 병상)	3~10명	10만~50만 행	광고 최적화 재원일수 분석	M5 Max 128GB	1~3개월	바로 가능
대학병원 (상급종합)	10~50명	100만~500만 행	경영 분석 병상 운영 최적화	M5 Ultra 256GB	3~6개월	조건부 가능
소규모 공공기관 지자체 연구소	3~15명	100만~1,000만 행	정책 분석 통계·예산 최적화	M5 Ultra ×1~2	6~12개월	조건부 가능
중앙부처 대형 공공기관	20~100명	1,000만~5,000만 행	스마트시티 국가통계 시뮬레이션	전용 서버 검토	12~24개월	장기 준비

6.3 장벽 분석 — 기술 vs 비기술

기술 (해결 가능)	망분리 지원	인터넷 연결 없는 에어갭 필요	로컬 LLM + 내부망 MCP 서버
기술 (해결 가능)	데이터 주권	환자/행정 데이터 외부 전송 불가	온프레미스 Air-Gap 배포
기술 (보완 필요)	고가용성	Mac Studio 자체 RAID 미지원	UPS + NAS RAID + 이중화
절차 (시간 필요)	나라장터 등록	공공기관 조달 플랫폼 등록	3~6개월 소요
절차 (시간 필요)	보안 심의	기관별 IT 보안 심사	기관마다 상이 (1~6개월)
인증 (최대 장벽)	GS인증	공공기관 소프트웨어 구매 필수	12~18개월, 5,000만~2억원
인증 (최대 장벽)	CC인증	중앙부처·국방 필수	18~24개월, 고비용
인증 (병원)	의료기기 해당 여부	XimTier는 경영분석 툴 — 의료기기 아님	식약처 확인 후 제외 가능

6.4 진입 순서 권장안

1단계 (지금): 광고형 병의원·전문병원 — 원장 직접 계약, 1~3개월, 레퍼런스 확보

2단계 (Seed): 대학병원 행정팀·지자체 연구소 — 3~6개월, GS인증 준비 시작

3단계 (Series A): 소규모 공공기관 — 나라장터 등록 완료 후, 6~12개월

4단계 (Series B 이후): 중앙부처·대형 공공기관 — GS/CC인증 완료 후, 12~24개월

공공·의료 레퍼런스의 시작은 병의원 SimSolution(광고 최적화)이다. 이 레퍼런스가 쌓여야 GS인증 투자를 정당화할 수 있고, 공공기관 입찰에서 실증 사례로 활용할 수 있다.

7.1 핵심 결론 요약

M5 Max 128GB 선택	Seed 충분 · M5 Ultra 256GB: Seed 이후 권장 · Mac Studio M5 출시(6~10월) 전 MacBook Pro M5 Max로 개발 시작 가능
LLM 인프라	Qwen 3.5 35B-A3B: 메인 엔진 · Gemma 4 26B: 규제 산업 전용 · 멀티 LLM 이중 구성으로 고객 선택권 제공
Phase 1~2 (3~5개월) 개발	Apple Code로 빠른 구현 가능 · Phase 3 비동기·격리 설계가 핵심 복잡도 · Anthropic MCP Marketplace 등록이 Phase 2 완료
Cloud/On-Prem 배포 전략	Gap 3단계 명확히 분리 · "데이터 주권" 주장은 On-Premise 이상에서만 가능 · Cloud는 편의성, 온프레미스는 신뢰성 포지셔닝
가동은 중요	비기술 장벽(GS인증·나라장터)이 핵심 · 병의원 SimSolution → 대학병원 → 공공기관 순서로 레퍼런스 축적

7.2 즉시 실행 항목 (이번 달)

1	MCP SDK 설치 및 reverse_whatif Tool 스키마 설계 시작	CTO 강승식	2주 이내
2	MacBook Pro M5 Max에서 Qwen 3.5 35B-A3B 로컬 실행 검증	CTO 강승식	1주 이내
3	Gemma 4 26B MoE vs Qwen 3.5 비교 테스트 (AI Q&A 품질)	CTO 강승식	2주 이내
4	Mac Studio M5 출시 일정 모니터링 (WWDC 2026.06.08)	CEO 한일	지속
5	광고형 병의원 파일럿 1호 고객 확보 및 온프레미스 배포 검증	CEO 한일	1개월
6	On-Premise MCP 배포 가이드 문서화 (고객사 설치 매뉴얼)	CTO 강승식	1개월

7.3 하드웨어 구매 타임라인 권장

지금 (개발 단계)	MacBook Pro M5 Max 64~128GB (기출시)	\$3,499~\$4,999	MCP 개발 + LLM 테스트
Mac Studio M5 출시 후 (2026.06~10)	Mac Studio M5 Max 128GB	~\$3,999~\$5,999	첫 고객 온프레미스 배포
Seed 라운드 후	Mac Studio M5 Ultra 256GB ×1~2	~\$7,999~\$11,999	다중 LLM + 고객 확장
Series A 이후	클라우드 GPU + Mac Studio 혼합	월 과금 전환	대규모 SaaS 운영

본 보고서는 XimTier의 기술 전략 수립을 위해 작성된 내부 검토 자료입니다.

하드웨어 가격 및 출시 일정은 Apple 공식 발표 전 추정치이며 변경될 수 있습니다.

LLM 벤치마크 수치는 MacBook Pro M5 Max 기준 실측값 (MLX 프레임워크, 2026.03~04 측정)입니다.

XimTier Inc. · CEO 한일 · CTO 강승식 · contact@ximtier.com · www.ximtier.com